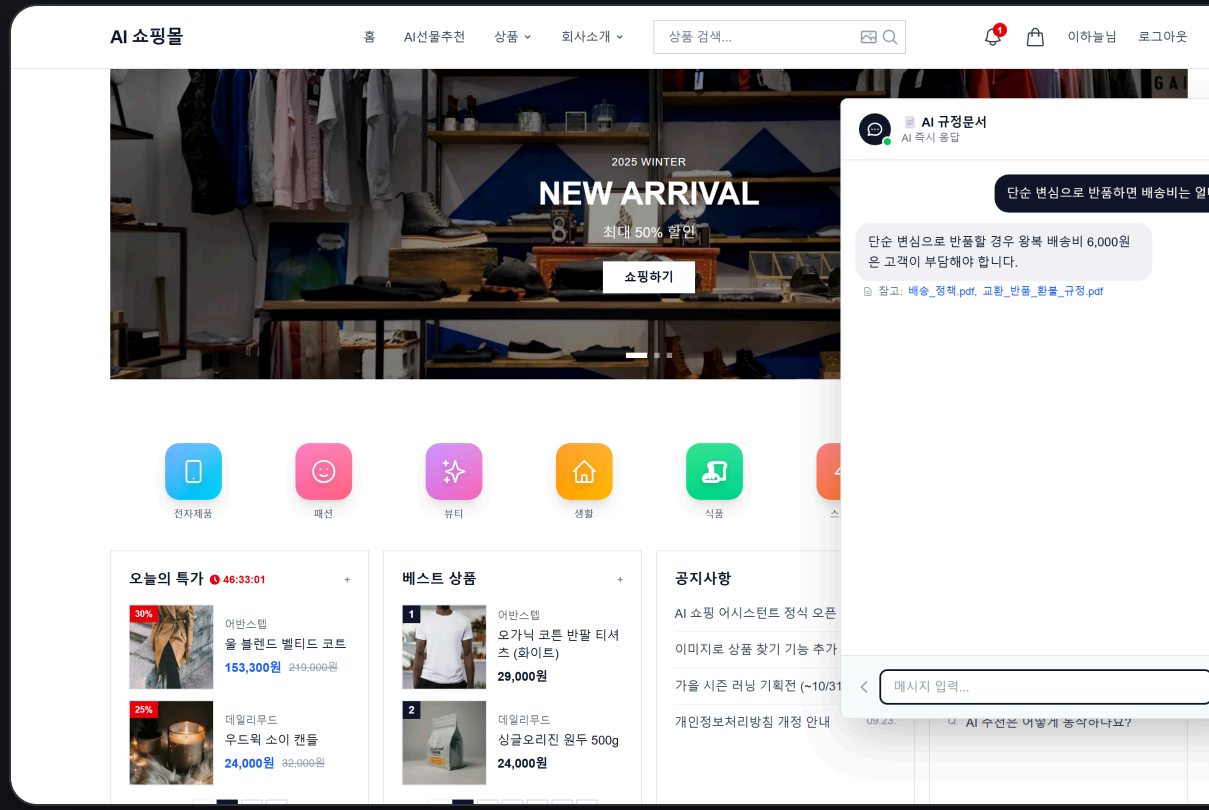
PORTFOLIO · RAG · LLM 서비스 개발

쇼핑몰에 붙인 RAG · 비전 검색 · LLM 추천

PDF 규정을 근거로 답하는 RAG 챗봇부터 사진 검색, 구매 이력 기반 추천까지 — 로컬 LLM으로 직접 만들고, **평가셋으로 환각과 프롬프트 잘림을 찾아낸** 기록입니다.

RAG · bge-m3 · CLIP · qwen2.5:14b · Ollama · pgvector · FastAPI · SSE



지원자 **최원준**

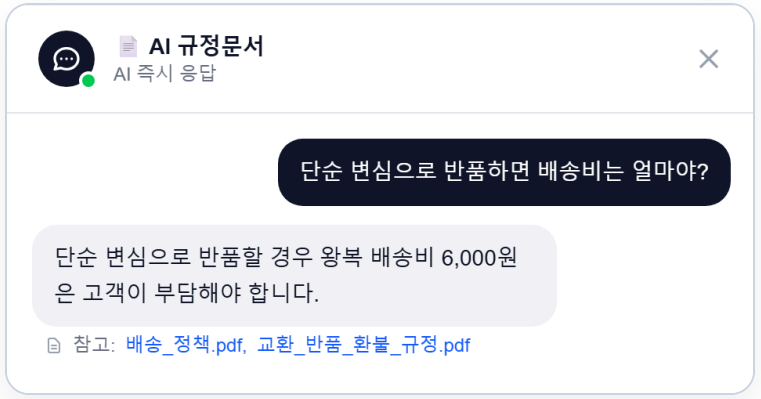
경력 **개발 경력 3년차**

프로젝트 **AI 쇼핑몰 · 재직 중 1인 개인 프로젝트**

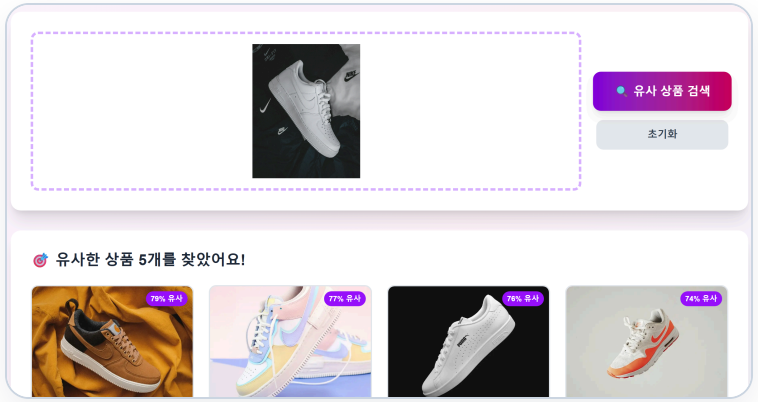
01 SERVICE

실제로 동작하는 AI 쇼핑몰 — 화면으로 먼저 보기

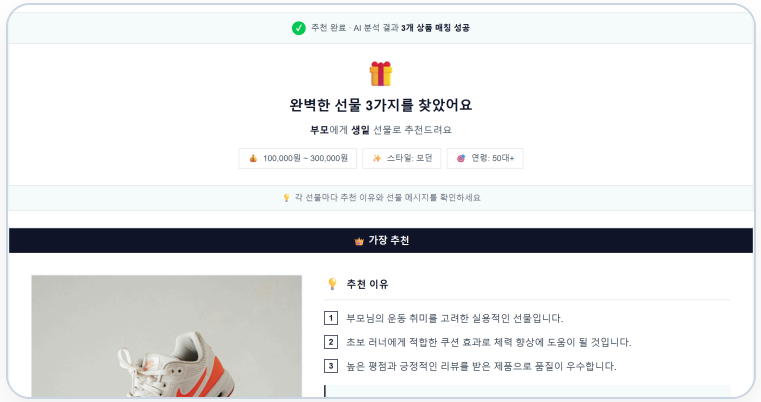
아래 화면은 모두 실제 앱을 돌려 캡처했습니다. 답변·추천·요약은 로컬 LLM(qwen2.5:14b)이 실시간으로 생성한 결과입니다.



01 **규정 상담 RAG** 규정 PDF를 근거로 답하고 출처 표시



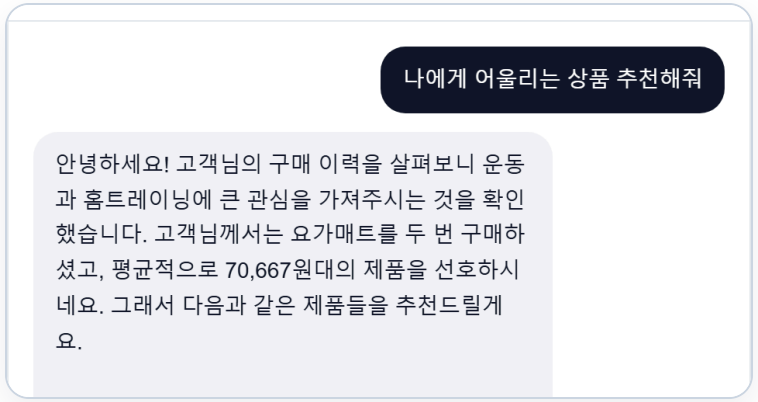
02 **사진으로 상품 찾기** CLIP 유사도 순 Top-5



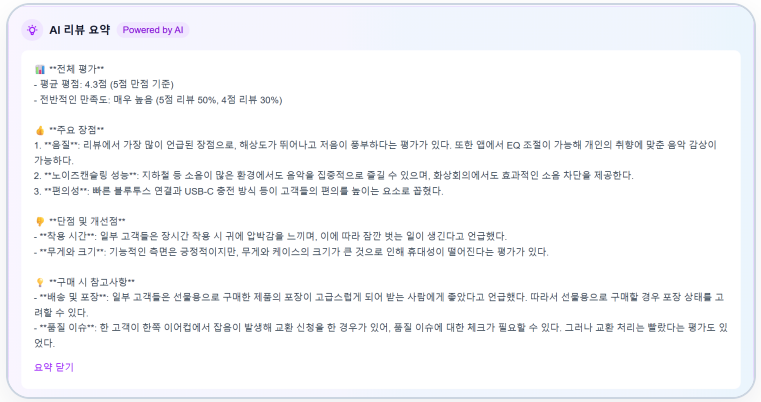
03 **AI 선물 마법사** 7개 질문 → 추천 3개 + 메시지



04 **쇼핑 추천 챗** 답변에 언급된 상품만 카드로



05 **개인화 추천** 구매 이력을 근거로 한 첫마디



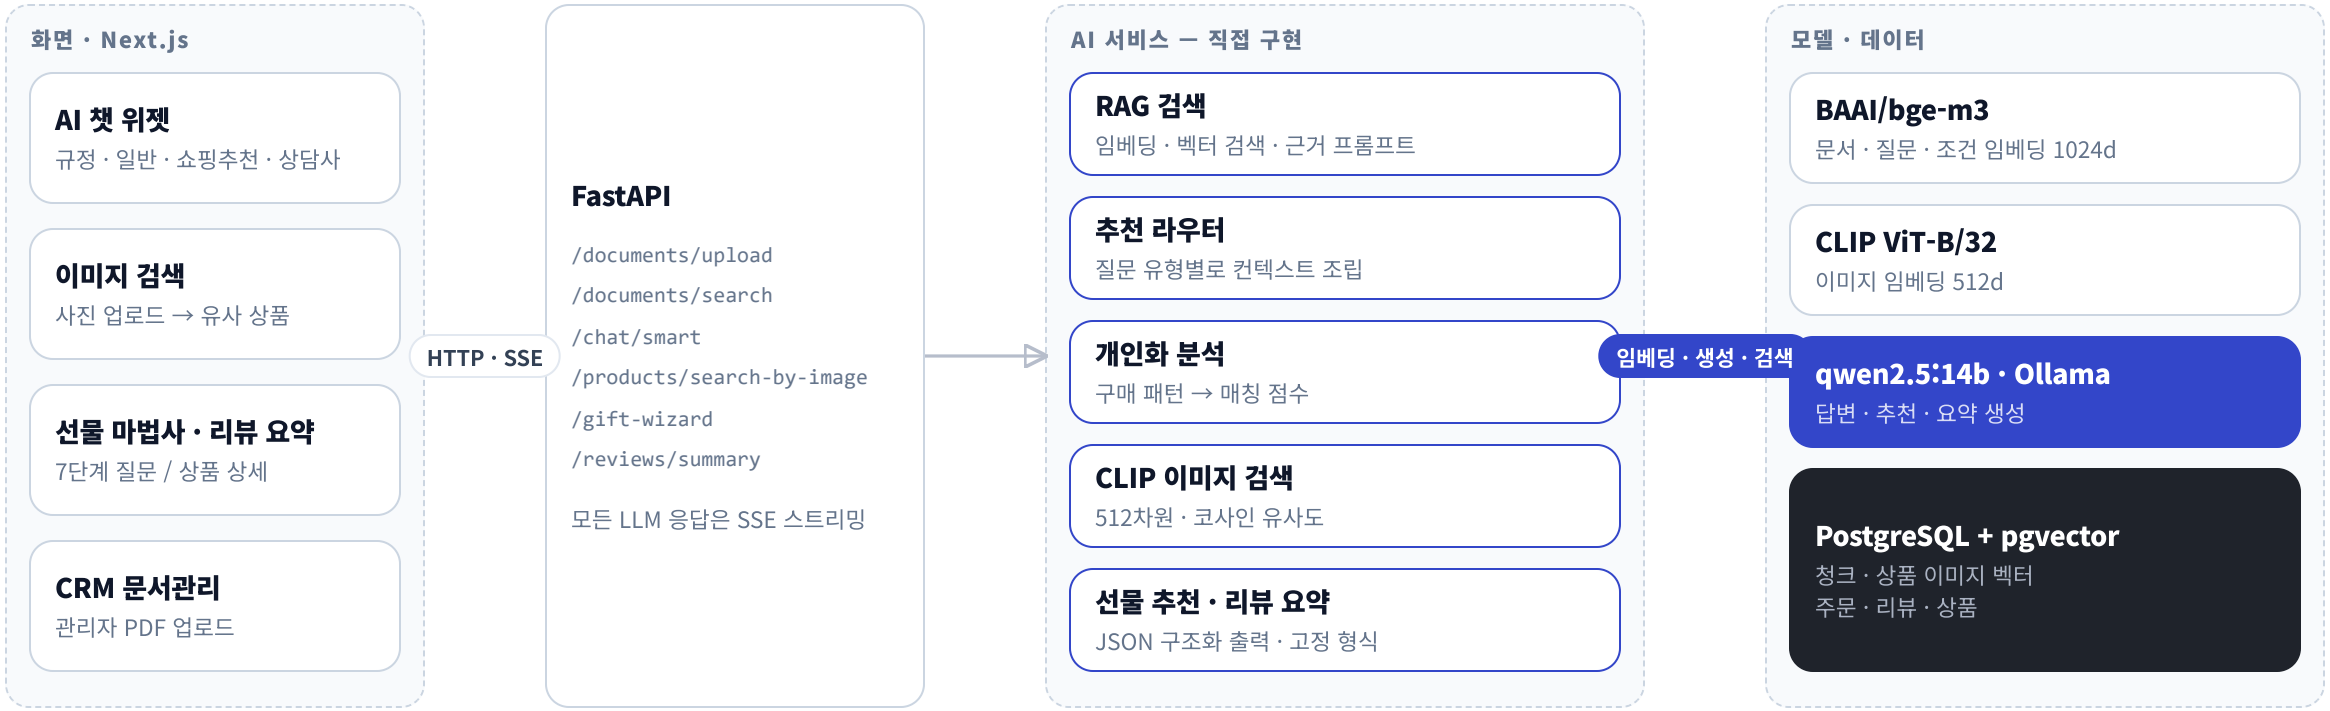
06 **AI 리뷰 요약** 장점 · 단점 · 구매 팁 4섹션

02 ROLE · ARCHITECTURE

기획부터 AI · 백엔드 · 화면까지, 혼자 만들었습니다

회사에 다니며 개인적으로 만든 1인 프로젝트입니다. 문서 색인부터 벡터 검색 · 프롬프트 · 스트리밍 · 화면까지 — **파란 테두리가 AI 모듈**입니다.

1인 개발	6개	3,300줄	0원
재직 중 개인 프로젝트 · 기획부터 배포 설정까지	AI 기능 (RAG · 추천 · 개인화 · 비전 · 선물 · 요약)	AI 모듈 Python 코드	외부 LLM API 비용 (로컬 추론)



03 RAG PIPELINE

업로드한 PDF가 출처 달린 답변이 되기까지

색인과 질문, 두 갈래가 **같은 임베딩 모델(bge-m3)**로 같은 벡터 공간에서 만납니다. 선 위 숫자는 실측값입니다.



왜 bge-m3?

규정·질문이 모두 한국어 — 다국어 모델 하나로 문서·질문·선물 조건까지 같은 벡터 공간

왜 500자 · 50자 겹침?

규정 한 조항이 한 청크에 — 경계에서 잘린 문장은 다음 청크에도 남게

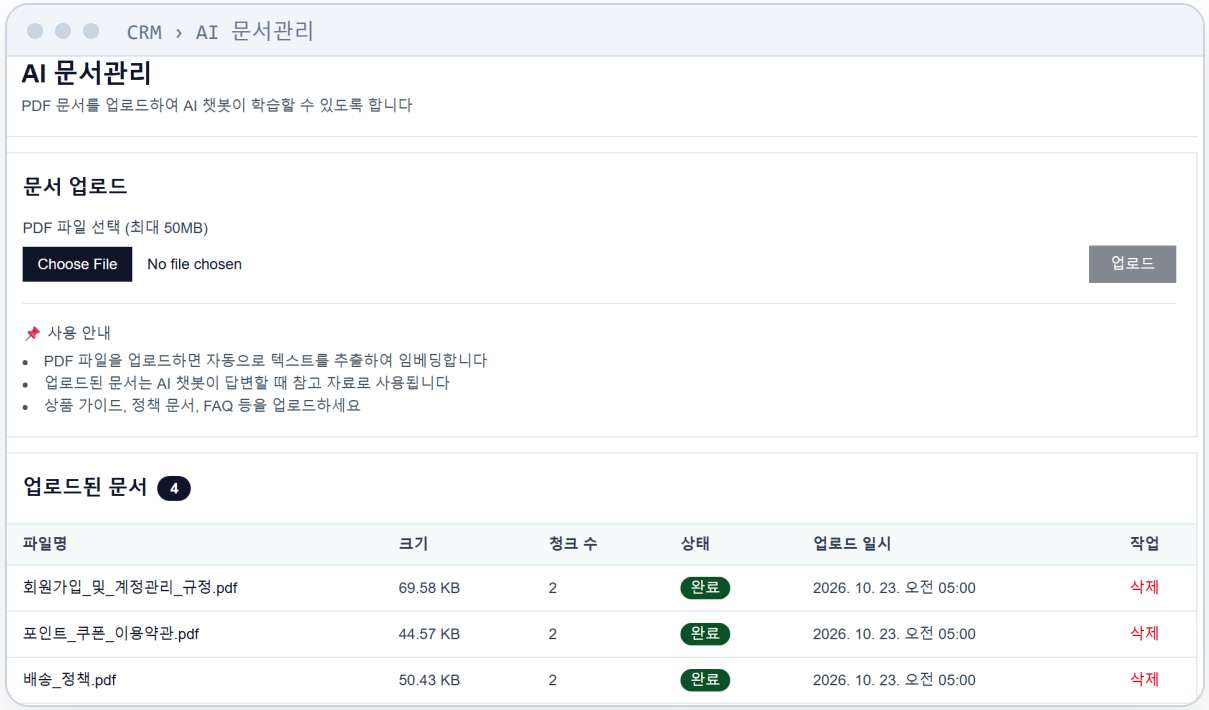
왜 별도 벡터 DB 없이?

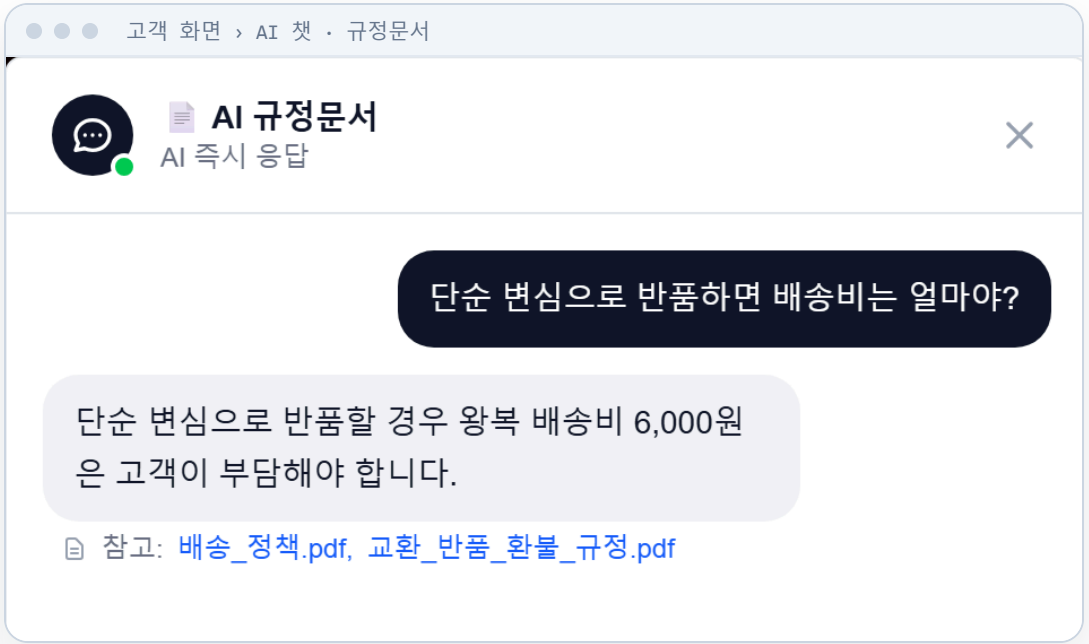
상품·주문과 같은 PostgreSQL(pgvector) — 조인이 쉽고 운영이 단순

04 RAG IN ACTION

관리자는 PDF만 올리고, 고객은 출처와 함께 답을 받습니다

같은 데이터가 두 화면을 잇습니다. 아래 막대는 이 질문 하나가 처리되는 시간(중앙값)입니다.







05 LLM ROUTER

질문을 읽고 길을 고르는 추천 챗

질문 유형에 따라 **LLM에 넣을 후보를 다르게 조립**하고, 답변이 끝나면 **LLM이 실제로 언급한 상품만** 카드로 돌려줍니다.





후보 3개 중 LLM이 답변에서 고른 **2개만** 실제 상품 카드로 — 존재하지 않는 상품 링크가 나가지 않습니다.

06 PERSONALIZATION

구매 이력 6건으로 취향을 읽고, LLM이 이유를 말합니다

점수는 **코드가 계산**하고(같은 사용자 → 같은 후보), LLM은 그 근거를 **사람 말로 설명**합니다.

① 최근 6개월 구매 이력



에어 플로우 러닝화 (레드)
2026-05-11 · 119,000원



논슬립 요가매트 8mm
2026-06-02 · 39,000원



오가닉 코튼 반팔 티셔츠 (화이트)
2026-06-02 · 29,000원



무선 이어버드 프로
2026-07-21 · 129,000원



조거 트레이닝 세트 (옐로우)
2026-08-30 · 69,000원



논슬립 요가매트 8mm
2026-10-02 · 39,000원

② 패턴 분석 (코드)

운동	5
홈트	3
요가	2
요가매트	2
헬스	2
트레이닝복	1

가격대	**29,000원 ~ 129,000원**
평균 구매가	**70,667원**
구매 주기	**분기별**
재구매	**논슬립 요가매트 8mm ×2**

> 매칭 점수 = 선호 태그 Top-5와 겹치는 수 · 가격대 ±30% · 이미 산 상품 제외

③ 추천 후보



스마트워치 액티브 (블랙)
매칭 2/5 · 159,000원



라이트핏 트레이닝화 (네온)
매칭 2/5 · 99,000원

④ LLM의 첫마디

안녕하세요! 고객님의 구매 이력을 살펴보니 운동과 홈트레이닝에 큰 관심을 가져주시는 것을 확인했습니다. 고객님께서는 요가매트를 두 번 구매하셨고, 평균적으로 70,667원대의 제품을 선호하시네요. 그래서 다음과 같은 제품들을 추천드릴게요.

07 VISION SEARCH

사진 한 장으로 비슷한 상품 찾기

상품 사진은 등록 때 미리 임베딩, 검색은 **질의 사진만 한 번** 임베딩 → 코사인 유사도. 아래는 **카탈로그에 없는 사진**으로 검색한 실제 결과입니다.



질의 운동화 사진

CLIP → 512d 코사인



1. 캔버스 하이 스니… 79%



2. 파스텔 플랫폼 스… 77%



3. 클래식 레더 스니… 76%



4. 쿠션 에어 러닝화 … 74%



5. 에어 플로우 러닝… 72%



질의 백팩 사진

CLIP → 512d 코사인



1. 데일리 백팩 (네… 88%



2. MA-1 봄버 자켓 (… 81%



3. 라탄 핸드백 80%



4. 미니 토트백 (레드) 78%



5. 패브릭 라운지 체… 78%

5 / 5	**1위 88%**	**99ms**	**43개**
운동화 사진 → 상위 5개 모두 신발	백팩 사진 → 데일리 백팩 (네이비)	업로드 → 결과 (CPU, 중앙값)	상품 이미지 벡터 (512차원)

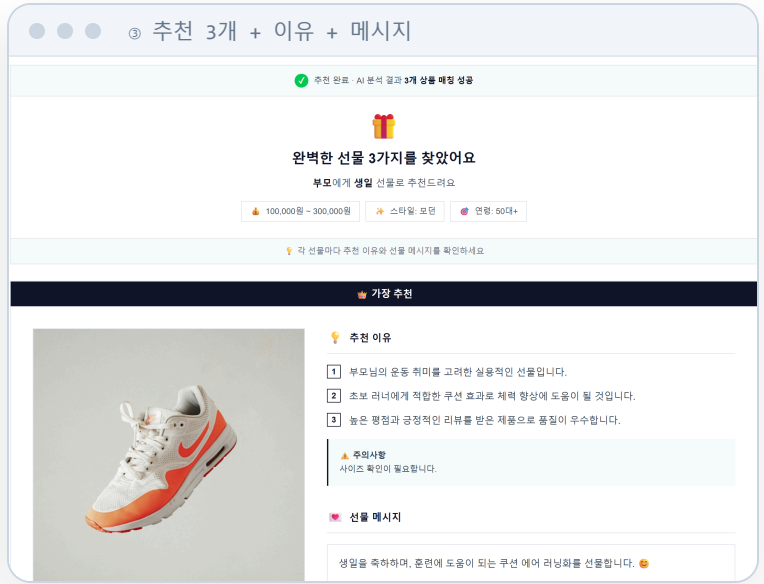
08 STRUCTURED OUTPUT

AI 선물 마법사 — LLM은 번호만 고르고, 상품 정보는 DB가 채웁니다

상품명을 LLM에게 쓰게 하지 않아 **존재하지 않는 상품이 추천될 여지를 구조적으로** 없앴습니다.







7개 답변
관계 · 연령 · 스타일
관심사 · 목적 · 예산

→

규칙표 → 의미 검색으로 교체
의미 기반 후보
조건 문장 ↔ 상품 텍스트
bge-m3 유사도 → 후보 32

후보 32

qwen2.5:14b → JSON
`{"rank": 1, "product_number": 10, "reasons": [3개], "gift_messages": [3톤]}`
※ `product_name` 은 쓰지 말 것

번호만

번호 → DB 매핑
products[10-1] →
실제 이름 · 가격 · 이미지

→

추천 카드 3장
+ 이유 3 · 메시지 3톤

09 GROUNDING

그럴듯한 오답을 막는 3겹 구조

원칙은 하나 — **LLM은 고르고 설명하고, 사실은 DB가 말한다.** 틀리면 곤란한 정보(상품명 · 가격 · 규정)는 코드에서 막습니다.



10 EVALUATION

평가셋 24문항을 직접 만들어 검증했습니다

규정 질문 20개(정답 문서 · 핵심 사실 표시)와 문서에 없는 질문 4개. 실제 API를 호출해 채점하는 스크립트(measure.py)로 언제든 다시 잴 수 있습니다.

채점 결과 — 24문항



■ 규정 질문 20 — 정답 문서 1순위 · 핵심 사실 포함
■ 문서 밖 질문 4 — "문서에서 찾을 수 없습니다"

채점 예시 (실제 답변)

단순 변심 반품 배송비?	**왕복 6,000원** 고객 부담	✓
도서산간 추가 배송비?	**5,000원** 추가	✓
향수 개봉 후 반품?	단순 변심 반품 **불가**	✓
멤버십 플러스 적립률?	1% + 2% = **3%**	✓
고객센터 전화번호?	"문서에서 찾을 수 없습니다"	✓

100%
Hit@1 — 1순위 청크가 정답 문서

100%
답변 정확도 — 금액·기간 등 핵심 사실

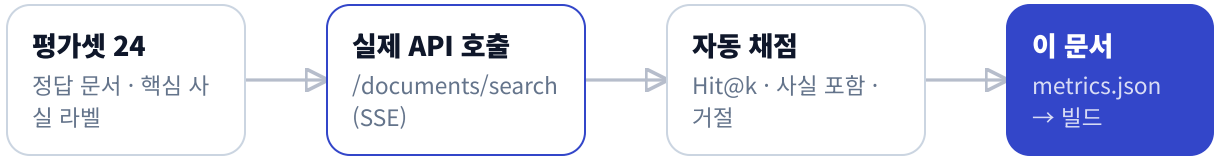
100%
거절률 — 문서에 없는 질문

106ms
질문 임베딩 (CPU)

11ms
벡터 검색

4.6s
첫 토큰 (로컬 14B)

자동 채점 흐름 — 숫자를 다시 만드는 방법



측정: 로컬 재현 환경 · qwen2.5:14b(RTX 5070, 다른 작업과 GPU 공유) · 시간은 중앙값

11 WHAT EVALUATION FOUND

평가로 찾아낸 문제 2가지 — 원인과 해결 설계까지

같은 질문을 여러 번 돌리고 프롬프트 토큰을 직접 세어 보니, 데모로는 보이지 않던 문제가 드러났습니다.

① 상품명 환각

개인화 답변 – 카탈로그에 없는 상품

```
1. **프로핏 요가브라 (블랙)**
   - 가격: 55,000원
   - 평점: 4.7/5.0 (10개 리뷰)
   - 판매량: 50개
   - 태그: 요가, 홈트, 운동, 요가용품, 헬스
   - 매칭 점수: 4/5 (고객님의 선호도와 매우 일치)

   **추천 이유**: 고객님께서 요가와 홈트레이닝을
```



원인 개인화 프롬프트에만 "목록에서 고르라"는 제약이 없고, 기구매 제외 후 후보가 2개뿐 → 모델이 그럴듯한 상품을 생성.
해결 선물 마법사처럼 **번호(ID)로 받고 DB가 채우기** + 답변 속 상품명 검증.

② 프롬프트 잘림 — 컨텍스트 4,096 토큰



Ollama server.log

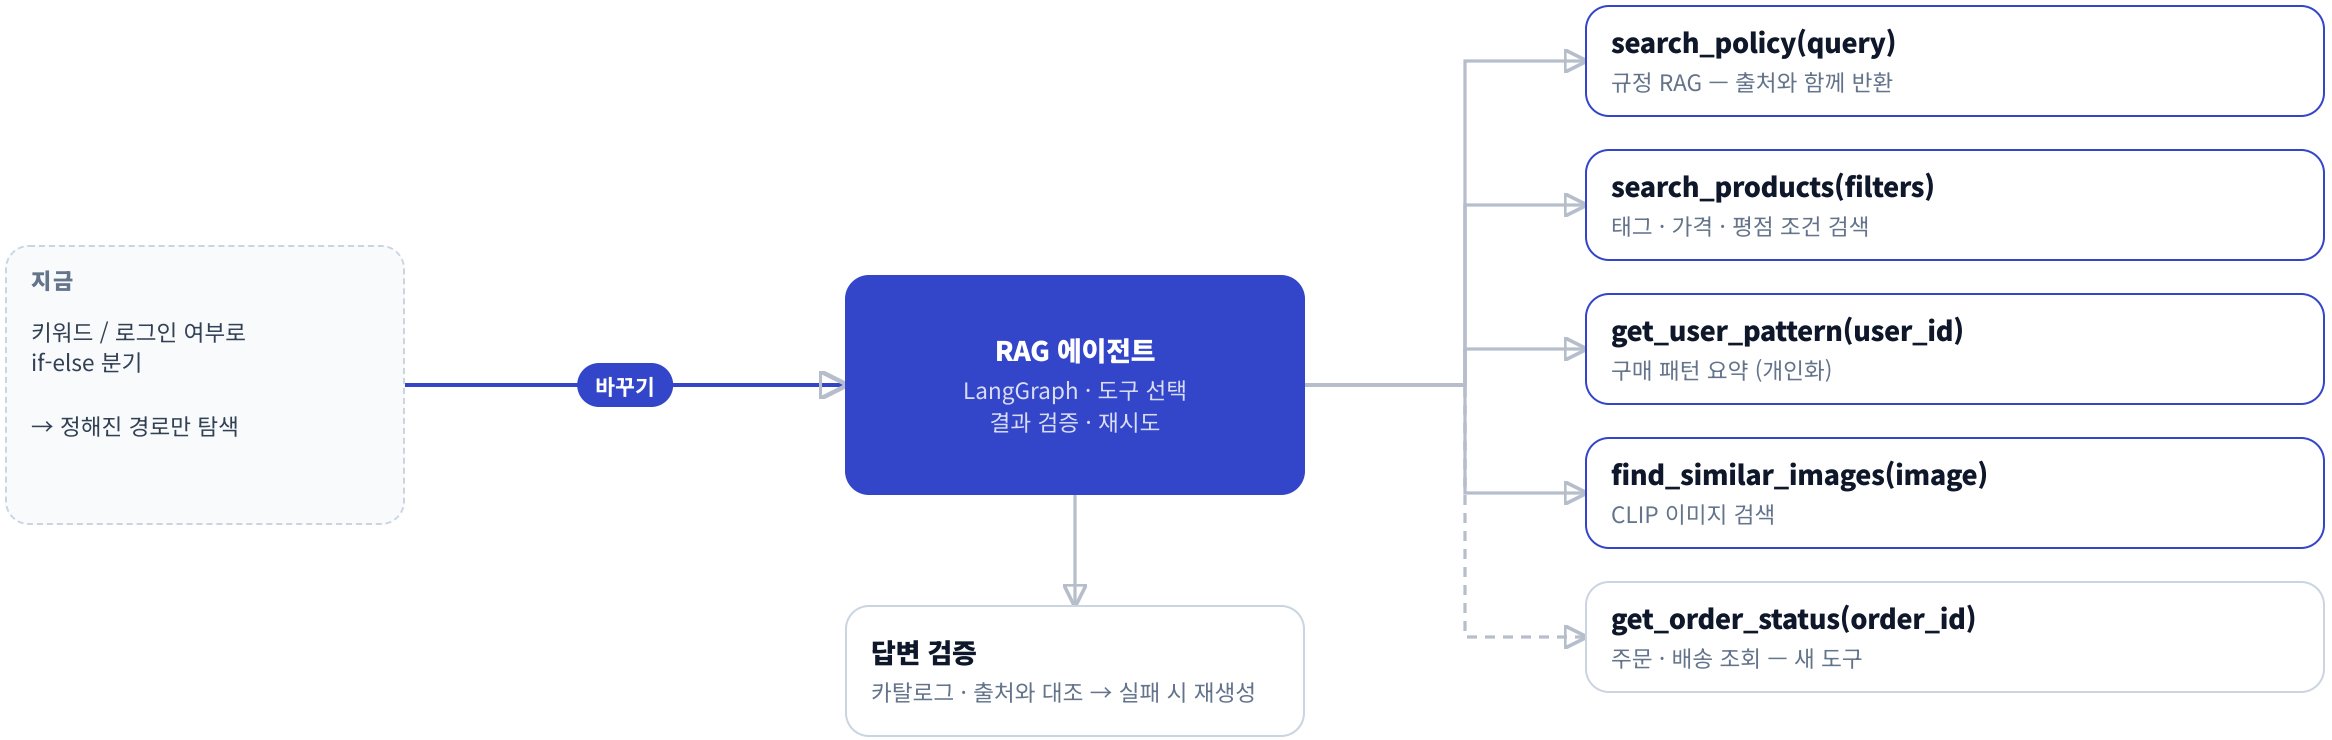
```
msg="truncating input prompt" prompt=4123 → new=2050
slot context shift, n_discard = 2045   # 선물 JSON 생성 중
```

원인 창 크기를 지정하지 않아 4,096으로 동작 → 넘치면 앞부분(지시문·상품 목록)이 버려짐.
해결 `num_ctx` 지정(모델은 32K) · 후보 50 → 15로 압축 · 리뷰는 1줄 요약.

12 NEXT · RAG AGENT

다음 단계 — 규칙 기반 라우터를 RAG 에이전트로

지금의 if-else 분기를 **모델이 도구를 고르고, 결과를 검증하는** 구조로 바꿉니다. 이미 만든 함수들이 그대로 도구가 됩니다.



최원준
RAG · LLM 서비스 개발 · 개발 경력 3년차

AI 쇼핑몰
재직 중 1인 개인 프로젝트

github.com/JongBeams/ShoppingMall
프로젝트 저장소